Univerzitet u Nišu
Elektronski fakultet
Katedra za računarstvo

Seminarski rad

Steganografija slika

Predmet: Studijsko-istraživački rad

Mentor:

Dr Aleksandar Dimitrijević

Student:

Miloš Veljanovski 1559

Niš, februar 2026.

Apstrakt

Steganografija predstavlja oblast informacionih tehnologija koja se bavi skrivanjem podataka unutar vidljivih digitalnih medija na način koji ne narušava njihov vizuelni ili perceptivni kvalitet. Za razliku od kriptografije, čiji je cilj da zaštiti sadržaj poruke njenim šifrovanjem, steganografija teži da sakrije samo postojanje poruke, čime se dodatno otežava njeno otkrivanje od strane neovlašćenih posmatrača. Digitalne slike, zbog svoje rasprostranjenosti, redundantnosti i specifičnih karakteristika ljudskog vizuelnog sistema, predstavljaju jedan od najpogodnijih nosača za steganografske tehnike.

Ovaj rad daje pregled razvoja steganografije slika, počevši od osnovnih koncepata i istorijskog konteksta, preko klasičnih tehnika prostornog i transformacionog domena, pa sve do savremenih metoda zasnovanih na adaptivnim algoritmima i modelima mašinskog učenja. Poseban akcenat stavljen je na poređenje različitih pristupa u pogledu kapaciteta skrivanja, neprimetnosti i otpornosti na obradu slike. U završnom delu rada razmatra se implementacija jedne od modernih steganografskih metoda, kao i analiza dobijenih eksperimentalnih rezultata. Cilj rada je da pruži sistematičan i pregledan uvid u savremene metode steganografije slika i ukaže na njihove prednosti, ograničenja i potencijalne pravce daljeg istraživanja.

Sadržaj

1. Uvod 6
2. Osnovni koncepti steganografije 7
   2.1. Osnovni pojmovi steganografije 7
   2.2. Steganografija i kriptografija – razlike i komplementarnost 8
   2.3. Kriterijumi kvaliteta steganografskih sistema 8
   2.4. Steganografija i srodne tehnike 8
3. Istorijski razvoj steganografije 9
   3.1. Rani oblici steganografije u antičkom svetu 9
   3.2. Steganografija u srednjem veku i ranom novom dobu 9
   3.3. Steganografija u 20. veku i vojna primena 10
   3.4. Prelazak na digitalnu steganografiju 10
   3.5. Savremeni pravci razvoja steganografije 10
4. Digitalne slike kao nosači informacija 11
   4.1. Digitalna reprezentacija slike 11
   4.2. Slike u boji i RGB model 11
   4.3. Redundantnost i ljudski vizuelni sistem 12
   4.4. Formati slika i njihov uticaj na steganografiju 12
   4.5. Uticaj obrade slike na skrivene poruke 12
5. Taksonomija modernih steganografskih tehnika za slike 13
   5.1. Tehnike prostornog domena 13
      5.1.1. Steganografija zasnovana na najmanje značajnom bitu (LSB) 13
      5.1.2. Sekvencijalna i pseudonasumična LSB ugrađivanja 14
      5.1.3. LSB matching i varijacije osnovne metode 14
      5.1.4. Prednosti i ograničenja tehnika prostornog domena 15
   5.2. Tehnike frekvencijskog domena (transformacije) 15
      5.2.1. Diskretna kosinusna transformacija (DCT) 15
      5.2.2. Steganografija u JPEG slikama 16
      5.2.3. Diskretna talasna transformacija (DWT) 16
      5.2.4. Hibridne DCT–DWT metode 17
      5.2.5. Prednosti i ograničenja frekvencijskog domena 17
   5.3. Adaptivne steganografske metode 17
      5.3.1. Steganografija zasnovana na ivicama (edge-based methods) 18

5.3.2. Steganografija zasnovana na teksturama 18
5.3.3. Metoda diferenciranja vrednosti piksela (Pixel Value Differencing – PVD) 18
5.3.4. Prednosti i ograničenja adaptivnih metoda 19
5.4. Model-based i statističke steganografske metode 19
5.4.1. Osnovni principi statističkog modelovanja u steganografiji 20
5.4.2. Histogram-based metode 20
5.4.3. OutGuess algoritam 20
5.4.4. F5 algoritam i matrično kodiranje 21
5.4.5. Prednosti i ograničenja model-based pristupa 21
5.5. Steganografija zasnovana na generativnim modelima 21
5.5.1. Osnovna ideja generativne steganografije 22
5.5.2. Steganografija zasnovana na generativnim suparničkim mrežama (GAN) 22
5.5.3. Autoenkoderi i varijacioni autoenkoderi (VAE) 22
5.5.4. Steganografija zasnovana na difuzionim modelima 23
5.5.5. Prednosti i izazovi generativnih pristupa 23
6. Analiza reprezentativnih steganografskih metoda 24
6.1. Kriterijumi poređenja 24
6.2. Poređenje metoda prostornog i frekvencijskog domena 24
6.3. Adaptivne metode u odnosu na uniformne pristupe 25
6.4. Statističke metode i otpornost na steganalizu 25
6.5. Prednosti savremenih generativnih pristupa 25
6.6. Izbor metode za implementaciju 26
7. Postavka sistema i metodologija evaluacije 26
7.1. Cilj eksperimenta 26
7.2. Opis sistema (end-to-end pipeline) 26
7.3. Skup podataka i priprema ulaza 27
7.4. Arhitektura modela 27
7.4.1. Enkoder (U-Net) 27
7.4.2. Dekoder (CNN) 28
7.5. Funkcija greške (loss) 28
7.6. Treniranje i hiperparametri 29
7.7. Metod evaluacije i metrike 29
8. Implementacija sistema 30

8.1. Tehnološki okvir i razvojno okruženje 30
8.2. Arhitektura enkoderske mreže 30
8.3. Dekoderska mreža 31
8.4. Funkcija gubitka 31
8.5. Procedura treniranja 32
8.6. Evaluacija i metrike 32
8.7. Vizuelni rezultati 33
8.8. Vizuelni rezultati 34
8.8.1. Graf funkcije gubitka 34
8.8.2. Graf PSNR metrike 34
8.8.3. Interpretacija rezultata 35
9. Eksperimentalni rezultati i analiza 35
9.1. Postavka eksperimenta 35
9.2. Kvantitativni rezultati 35
9.3. Vizuelni rezultati 36
9.4. Analiza konvergencije 37
9.5. Analiza konvergencije 38
10. Zaključak 39
11. Literatura 40
12. Listing 41

1. Uvod

U savremenom digitalnom društvu razmena informacija predstavlja osnovu gotovo svih oblika komunikacije, od privatnih razgovora do poslovnih i državnih sistema. Razvoj interneta i digitalnih medija omogućio je brz i jednostavan prenos velikih količina podataka, ali je istovremeno doveo i do povećanih bezbednosnih izazova. Pitanje zaštite informacija, njihove privatnosti i integriteta postalo je jedno od ključnih problema modernih informacionih sistema.

Tradicionalni pristupi bezbednosti komunikacije uglavnom se oslanjaju na kriptografiju, čiji je osnovni cilj da sadržaj poruke učini nečitljivim neovlašćenim korisnicima. Iako kriptografske metode pružaju visok nivo zaštite podataka, one ne skrivaju činjenicu da komunikacija postoji. Šifrovani sadržaj je lako uočljiv i samim tim može privući pažnju potencijalnih napadača, čak i kada oni nisu u mogućnosti da poruku dešifruju. U takvim situacijama, sama detekcija zaštićene komunikacije može predstavljati bezbednosni rizik.

Steganografija nudi drugačiji pristup ovom problemu. Umesto da se fokusira isključivo na zaštitu sadržaja poruke, steganografija ima za cilj da sakrije samo postojanje poruke, ugrađujući je u neki naizgled bezopasan medijum, poput slike, zvučnog zapisa ili video-snimka. Na taj način, komunikacija ostaje neprimetna i ne izaziva sumnju, što steganografiju čini posebno pogodnom za scenarije u kojima je diskretnost od presudnog značaja. U praksi, steganografija se često koristi u kombinaciji sa kriptografijom, čime se postiže višeslojna zaštita informacija.

Među različitim vrstama digitalnih medija, slike zauzimaju posebno mesto u steganografiji. Digitalne slike su široko rasprostranjene na internetu, poseduju značajnu količinu redundantnih podataka i oslanjaju se na ograničenja ljudskog vizuelnog sistema, koji je relativno neosetljiv na male promene intenziteta boja ili osvetljenja. Ove karakteristike omogućavaju ugrađivanje skrivene poruke bez vidljivog narušavanja kvaliteta slike, što slike čini idealnim nosačima steganografskih informacija.

Razvoj steganografije slika pratio je napredak digitalne obrade slike i računarskih sistema. Rani pristupi zasnivali su se na jednostavnim tehnikama u prostornom domenu, kao što je manipulacija najmanje značajnih bitova piksela. Iako su ove metode lake za implementaciju i imaju relativno veliki kapacitet skrivanja, one često pate od slabe otpornosti na obradu slike, kao što su kompresija ili dodavanje šuma. Sa razvojem sofisticiranijih algoritama, uvedene su metode u transformacionom domenu, koje koriste matematičke transformacije poput diskretne kosinusne ili talasne transformacije, čime se postiže veća robusnost i neprimetnost.

U poslednjih nekoliko godina, steganografija slika doživela je značajan napredak zahvaljujući primeni metoda mašinskog učenja i dubokih neuronskih mreža. Generativni modeli, poput generativnih suparničkih mreža (GAN) i difuzionih modela, omogućili su razvoj steganografskih sistema koji su znatno teži za detekciju i bolje prilagođeni statističkim karakteristikama prirodnih slika. Ovi savremeni pristupi predstavljaju trenutno najaktivnije područje istraživanja u oblasti steganografije.

Cilj ovog rada je da pruži sistematičan pregled steganografije slika, sa posebnim naglaskom na moderne metode i njihovu praktičnu primenu. Rad obuhvata osnovne

koncepte i istorijski razvoj steganografije, analizu digitalnih slika kao nosača informacija, pregled i klasifikaciju savremenih steganografskih tehnika, kao i implementaciju i eksperimentalnu evaluaciju jedne od modernih metoda. Na taj način, rad nastoji da objedini teorijski i praktični aspekt ove oblasti i pruži osnovu za dalja istraživanja u domenu bezbedne i neprimetne komunikacije.

2. Osnovni koncepti steganografije

Steganografija predstavlja tehniku skrivanja informacija unutar drugih, naizgled bezopasnih podataka, sa ciljem da se sakrije samo postojanje tajne poruke. Za razliku od klasičnih metoda zaštite podataka koje se fokusiraju na sadržaj poruke, steganografija se bavi načinima na koje se poruka može neprimetno uklopiti u postojeći medijum, tako da treća strana ne može ni da nasluti da se komunikacija odvija. Ovaj pristup čini steganografiju posebno pogodnom za scenarije u kojima je diskretnost komunikacije od presudnog značaja.

U digitalnom kontekstu, steganografija se najčešće primenjuje na medije koji poseduju određeni stepen redundanse, odnosno delove podataka čije se vrednosti mogu blago menjati bez primetnog uticaja na krajnju percepciju. Digitalne slike, zvučni zapisi i video-snimci predstavljaju tipične primere takvih nosača, pri čemu su slike najčešće korišćeni medijum zbog svoje rasprostranjenosti i relativno jednostavne strukture.

2.1. Osnovni pojmovi steganografije

Steganografski sistem se u najopštijem obliku sastoji od nekoliko ključnih elemenata. **Nosač** (engl. *Cover medium*) predstavlja originalni digitalni objekat u koji se ugrađuje tajna poruka. U kontekstu ovog rada, nosač je digitalna slika. **Tajna poruka** (engl. *Secret message*) predstavlja informaciju koja se želi sakriti i ona može biti u različitim oblicima, kao što su tekst, binarni podaci ili čak druga slika.

Proces ugrađivanja rezultuje **stego-objektom** (engl. *Stego-image*), odnosno slikom koja sadrži skrivenu poruku, ali vizuelno ne odstupa značajno od originalnog nosača. Za pravilno izvlačenje skrivene poruke često je potreban **stego-ključ**, koji predstavlja dodatnu tajnu informaciju i može se koristiti za određivanje lokacija u slici gde su podaci ugrađeni ili za inicijalizaciju pseudoslučajnih procesa u algoritmu.

U formalnom smislu, steganografski sistem može se posmatrati kao funkcija koja, na osnovu nosača, tajne poruke i opcionalnog ključa, proizvodi stego-sliku. Obrnuti proces, ekstrakcija, koristi stego-sliku i ključ kako bi se rekonstruisala originalna poruka. Bez poznavanja ključa ili samog algoritma, trećoj strani je izuzetno teško da utvrdi postojanje skrivene informacije.

2.2. Steganografija i kriptografija – razlike i komplementarnost

Iako se steganografija i kriptografija često pominju zajedno, njihovi ciljevi su suštinski različiti. Kriptografija ima za cilj da sadržaj poruke učini nečitljivim neovlašćenim korisnicima, koristeći algoritme za šifrovanje koji transformišu podatke u neprepoznatljiv oblik. Međutim, kriptografski zaštićena poruka je lako uočljiva, jer je očigledno da se radi o šifrovanim podacima.

Steganografija, s druge strane, ne menja suštinski strukturu poruke, već pokušava da je sakrije unutar drugog medijuma, tako da sama komunikacija ostane neprimećena. U tom smislu, steganografija ne zamenjuje kriptografiju, već je dopunjuje. U praksi se često primenjuje kombinacija ove dve tehnike, gde se poruka prvo šifruje kriptografskim algoritmom, a zatim se tako šifrovana poruka ugrađuje u sliku pomoću steganografskog algoritma. Na taj način, čak i u slučaju da steganografska zaštita bude kompromitovana, sadržaj poruke ostaje zaštićen kriptografijom.

2.3. Kriterijumi kvaliteta steganografskih sistema

Efikasnost steganografskog sistema može se oceniti na osnovu nekoliko ključnih kriterijuma. Jedan od najvažnijih je **neprimetnost** (engl. *imperceptibility*), koja opisuje koliko je teško uočiti razliku između originalne i stego-slike, bilo ljudskim okom ili pomoću statističkih analiza. Idealna stego-slika treba da bude vizuelno i statistički gotovo identična originalnom nosaču.

Drugi važan kriterijum je **kapacitet skrivanja**, koji predstavlja količinu podataka koja se može bezbedno ugraditi u nosač, a da se pritom ne naruši neprimetnost. Veći kapacitet omogućava skrivanje većih poruka, ali često dolazi po cenu smanjene otpornosti ili veće verovatnoće detekcije.

Treći kriterijum je **robustnost**, koja se odnosi na sposobnost steganografskog sistema da sačuva skrivenu poruku prilikom različitih transformacija stego-slike, kao što su kompresija, skaliranje, rotacija ili dodavanje šuma. Dok neke tehnike nude visok kapacitet i neprimetnost, one mogu biti veoma osetljive na čak i minimalne promene slike, što ih čini nepraktičnim u realnim uslovima.

U praksi, dizajn steganografskog sistema podrazumeva kompromis između ova tri kriterijuma, jer je gotovo nemoguće istovremeno maksimizovati neprimetnost, kapacitet i robustnost.

2.4. Steganografija i srodne tehnike

Važno je razlikovati steganografiju od srodnih tehnika, kao što su digitalni vodeni žigovi i digitalni otisci prstiju. Iako se i ove metode oslanjaju na ugrađivanje dodatnih informacija u digitalne medije, njihova namena je drugačija. Digitalni vodeni žigovi se

uglavnom koriste za zaštitu autorskih prava i dokazivanje vlasništva nad digitalnim sadržajem, pri čemu je često poželjno da ugrađena informacija bude otporna na različite obrade slike, čak i po cenu blagog narušavanja kvaliteta.

Steganografija, za razliku od toga, ima primarni cilj da sakrije samu činjenicu postojanja poruke. Zbog toga su zahtevi za neprimetnost znatno stroži, a tehnike koje se koriste često se fokusiraju na minimalne i pažljivo odabrane modifikacije nosača. Ova razlika u ciljevima dovodi do značajnih razlika u dizajnu algoritama i kriterijumima njihove evaluacije.

3. Istorijski razvoj steganografije

Potreba za tajnom komunikacijom prisutna je kroz čitavu istoriju čovečanstva. Još od najranijih civilizacija, ljudi su tražili načine da prenesu informacije tako da one ostanu skrivene od nepoželjnih posmatrača. Steganografija, kao tehnika skrivanja samog postojanja poruke, razvijala se paralelno sa razvojem društva, tehnologije i komunikacionih kanala, prilagođavajući se dostupnim medijima i potrebama određenog istorijskog perioda.

3.1. Rani oblici steganografije u antičkom svetu

Sam termin *steganografija* potiče od grčkih reči *steganos* (skriven) i *graphein* (pisati), što doslovno znači „skriveno pisanje“. Jedan od najpoznatijih ranih primera steganografije potiče iz antičke Grčke i vezuje se za grčkog vladara Histieja iz 5. veka pre nove ere. Prema zapisima Herodota, Histiej je, kako bi poslao tajnu poruku svom savezniku, obrijao glavu roba, istetovirao poruku na njegovom temenu, a zatim sačekao da kosa ponovo izraste pre nego što ga pošalje na odredište. Na taj način, poruka je ostajala potpuno nevidljiva tokom transporta.

Još jedan primer iz istog perioda uključuje korišćenje voštanih tablica. Poruka bi se pisala direktno na drvenu podlogu table, nakon čega bi bila prekrivena slojem voska i naizgled ostajala prazna. Primalac poruke bi jednostavnim uklanjanjem voska mogao da otkrije skriveni sadržaj. Ove tehnike jasno ilustruju osnovni princip steganografije – skrivanje informacije unutar drugog, bezazlenog objekta.

3.2. Steganografija u srednjem veku i ranom novom dobu

Tokom srednjeg veka i ranog novog doba, steganografske tehnike postale su sofisticiranije, naročito u kontekstu političkih intriga, diplomatije i ratovanja. Jedna od najpoznatijih metoda tog vremena bila je upotreba nevidljivih mastila. Supstance poput

limunovog soka, mleka ili određenih hemikalija korišćene su za pisanje poruka koje su postajale vidljive tek nakon zagrevanja papira ili primene specifičnih reagensa.

Značajan doprinos razvoju steganografije dao je italijanski matematičar Đirolamo Kardano u 16. veku, koji je opisao tehniku korišćenja kartonske maske sa otvorima. Poruka bi se pisala samo u predviđenim otvorima, dok bi ostatak teksta bio popunjen bezazlenim sadržajem, čineći poruku neprimetnom za neupućenog čitaoca. Ovaj pristup predstavlja jedan od prvih sistematizovanih pokušaja formalizacije steganografskih metoda.

3.3. Steganografija u 20. veku i vojna primena

Razvoj modernih komunikacija tokom 20. veka doveo je do šire i intenzivnije upotrebe steganografije, posebno u vojnim i obaveštajnim operacijama. Tokom Prvog i Drugog svetskog rata, steganografija je korišćena u kombinaciji sa kriptografijom kako bi se obezbedila tajna razmena informacija.

Jedna od najpoznatijih tehnika iz tog perioda bila je takozvana *mikrotačka* (*microdot*), gde su čitavi dokumenti ili slike smanjivani na veličinu tačke i skrivani unutar interpunkcijskih znakova ili slika. Ovakve poruke bile su izuzetno teške za detekciju bez specijalizovane opreme i znanja, što ih je činilo veoma efikasnim sredstvom tajne komunikacije.

3.4. Prelazak na digitalnu steganografiju

Pojavom računara i digitalnih medija krajem 20. veka, steganografija je doživela značajnu transformaciju. Analogni mediji zamenjeni su digitalnim formatima, a binarna reprezentacija podataka otvorila je nove mogućnosti za skrivanje informacija. Digitalne slike, zvučni zapisi i video-snimci postali su novi nosači steganografskih poruka.

Rane digitalne tehnike bile su relativno jednostavne i oslanjale su se na direktnu manipulaciju bitova podataka, poput izmene najmanje značajnih bitova piksela u slici. Iako su ove metode bile lake za implementaciju i nudile veliki kapacitet skrivanja, ubrzo su se pojavile i tehnike za njihovu detekciju, poznate pod zajedničkim nazivom steganaliza.

3.5. Savremeni pravci razvoja steganografije

Savremena steganografija razvija se u tesnoj vezi sa napretkom digitalne obrade signala i veštačke inteligencije. Kako su steganalitičke metode postajale sofisticiranije, javila se potreba za razvojem adaptivnih i statistički neprimetnih steganografskih

algoritama. To je dovelo do uvođenja tehnika u transformacionom domenu, kao i metoda koje se prilagođavaju lokalnim karakteristikama slike.

U poslednjoj deceniji, primena dubokih neuronskih mreža i generativnih modela označila je novi korak u razvoju steganografije. Ovi pristupi omogućavaju automatsko učenje optimalnih strategija za skrivanje informacija i znatno otežavaju njihovu detekciju. Steganografija je tako prešla put od jednostavnih fizičkih trikova do kompleksnih algoritamskih sistema, čineći je jednom od najdinamičnijih oblasti savremene informacione bezbednosti.

4. Digitalne slike kao nosači informacija

Digitalne slike predstavljaju jedan od najpogodnijih medija za primenu steganografskih tehnika. Njihova široka rasprostranjenost na internetu, velika količina podataka koju sadrže, kao i specifične karakteristike ljudskog vizuelnog sistema, čine ih idealnim nosačima za skrivanje informacija. Da bi se razumeli principi steganografije slika, neophodno je najpre sagledati način na koji su digitalne slike predstavljene i obrađene u računarskim sistemima.

4.1. Digitalna reprezentacija slike

Digitalna slika se može posmatrati kao dvodimenzionalna matrica piksela, gde svaki piksel predstavlja najmanju jedinicu slike i nosi informaciju o intenzitetu svetlosti ili boje na određenoj poziciji. Vrednosti piksela su kvantizovane i obično se predstavljaju celobrojnim vrednostima ograničenog opsega, što omogućava njihovo skladištenje i obradu u digitalnom obliku.

U najjednostavnijem slučaju, slike mogu biti predstavljene u sivim tonovima, gde se svakom pikselu dodeljuje jedna vrednost intenziteta. Najčešće se koristi 8-bitna reprezentacija, koja omogućava prikaz 256 različitih nijansi sive. Ovakav tip slike je jednostavan za analizu i često se koristi u istraživačkim radovima kao polazni model za razvoj steganografskih algoritama.

4.2. Slike u boji i RGB model

Većina digitalnih slika u realnim aplikacijama koristi modele boja koji kombinuju više kanala. Najrasprostranjeniji je RGB model, u kome se boja svakog piksela opisuje pomoću tri komponente: crvene (R), zelene (G) i plave (B). Svaka od ovih komponenti se obično predstavlja sa 8 bitova, što ukupno daje 24-bitnu reprezentaciju piksela i omogućava prikaz preko 16 miliona različitih boja.

Ovakva struktura slike pruža dodatnu fleksibilnost za steganografiju, jer omogućava skrivanje informacija ne samo u pojedinačnim pikselima, već i u različitim kanalima boje. Male promene u vrednostima jednog kanala često su neprimetne ljudskom oku, posebno kada su ravnomerno raspoređene ili smeštene u oblasti slike sa visokim nivoom detalja.

4.3. Redundantnost i ljudski vizuelni sistem

Jedan od ključnih razloga zbog kojih su slike pogodne za steganografiju leži u osobinama ljudskog vizuelnog sistema. Ljudsko oko nije podjednako osetljivo na sve vrste vizuelnih promena. Male promene u intenzitetu boje ili osvetljenja, naročito u oblastima slike koje sadrže teksture, ivice ili šum, često prolaze nezapaženo.

Digitalne slike takođe sadrže značajnu količinu redundantnih informacija. Redundantni delovi slike su oni čija se vrednost može blago promeniti bez vidljivog uticaja na celokupni izgled slike. Steganografske tehnike upravo koriste ovu redundantnost kako bi ugradile skrivene podatke na način koji ne narušava vizuelni kvalitet nosača.

4.4. Formati slika i njihov uticaj na steganografiju

Izbor formata slike ima značajan uticaj na dizajn i efikasnost steganografskih metoda. Formati slika se mogu grubo podeliti na one koji koriste kompresiju bez gubitaka i one koji koriste kompresiju sa gubicima.

Formati bez gubitaka, poput BMP i PNG, čuvaju sve informacije o originalnoj slici i omogućavaju tačnu rekonstrukciju podataka. Zbog toga su ovi formati posebno pogodni za tehnike prostornog domena, kao što je zamena najmanje značajnih bitova piksela. Nedostatak ovih formata ogleda se u većim veličinama datoteka, što ih čini manje praktičnim za svakodnevnu upotrebu na internetu.

S druge strane, JPEG format koristi kompresiju sa gubicima, pri čemu se određeni delovi slike trajno uklanjaju kako bi se smanjila veličina datoteke. Iako JPEG slike nude znatno manju veličinu i široku primenu, kompresija sa gubicima otežava primenu jednostavnih steganografskih tehnika. Zbog toga su za JPEG format razvijene specijalizovane metode koje rade u transformacionom domenu, kao što su tehnike zasnovane na diskretnoj kosinusnoj transformaciji.

4.5. Uticaj obrade slike na skrivene poruke

Jedan od najvećih izazova u steganografiji slika predstavlja otpornost skrivene poruke na različite obrade slike. Operacije poput kompresije, promene rezolucije, rotacije

ili dodavanja šuma mogu značajno uticati na integritet ugrađenih podataka. Tehnike koje nude visok kapacitet skrivanja često su veoma osetljive na ovakve transformacije, dok robusnije metode obično zahtevaju složenije algoritme i nude manji kapacitet.

Razumevanje odnosa između strukture digitalne slike i načina na koji se ona obrađuje ključno je za izbor odgovarajuće steganografske tehnike. Ova veza predstavlja osnovu za razvoj savremenih metoda koje pokušavaju da postignu optimalan kompromis između neprimetnosti, kapaciteta i robusnosti.

5. Taksonomija modernih steganografskih tehnika za slike

Razvoj steganografije slika doveo je do pojave velikog broja različitih tehnika i algoritama koji se međusobno razlikuju po načinu ugrađivanja poruke, otpornosti na obradu slike, kapacitetu skrivanja i složenosti implementacije. Kako bi se ove tehnike sistematično analizirale i uporedile, neophodno je uvesti jasnu taksonomiju steganografskih pristupa.

Jedan od najčešće korišćenih kriterijuma za klasifikaciju steganografskih metoda zasniva se na domenu u kome se vrši ugrađivanje informacije. Prema ovom kriterijumu, tehnike se mogu podeliti na metode koje direktno modifikuju vrednosti piksela u prostornom domenu, metode koje rade u transformacionom (frekvencijskom) domenu, adaptivne metode koje se prilagođavaju lokalnim karakteristikama slike, kao i savremene pristupe zasnovane na statističkim modelima i dubokom učenju.

U ovom poglavlju dat je pregled najvažnijih steganografskih tehnika za slike, poređanih od jednostavnijih i ranije razvijenih pristupa ka savremenim i kompleksnijim metodama koje predstavljaju aktuelni fokus istraživanja.

5.1. Tehnike prostornog domena

Tehnike prostornog domena predstavljaju najranije i konceptualno najjednostavnije steganografske metode za slike. Osnovna ideja ovih tehnika zasniva se na direktnoj manipulaciji vrednostima piksela u digitalnoj slici, bez primene matematičkih transformacija. Zbog svoje jednostavnosti i relativno velikog kapaciteta skrivanja, ove metode su i danas široko zastupljene, posebno u edukativne i eksperimentalne svrhe.

5.1.1. Steganografija zasnovana na najmanje značajnom bitu (LSB)

Najpoznatija i najčešće korišćena tehnika prostornog domena je metoda zasnovana na izmeni najmanje značajnog bita piksela, poznata kao **LSB (Least Significant Bit) steganografija**. U digitalnoj slici, svaki piksel je predstavljen binarnom

vrednošću, pri čemu najmanje značajni bit ima najmanji uticaj na vizuelni izgled slike. Zamena ovog bita odgovarajućim bitom tajne poruke obično ne dovodi do vidljivih promena u slici.

Na primer, u 8-bitnoj slici u sivim tonovima, promena najmanje značajnog bita menja intenzitet piksela za najviše jednu jedinicu, što je u većini slučajeva neprimetno ljudskom oku. U RGB slikama, LSB modifikacija se može primeniti nezavisno na svaki kanal boje, čime se dodatno povećava kapacitet skrivanja.

Prednost LSB metode ogleda se u njenoj jednostavnoj implementaciji i velikom kapacitetu, dok se glavni nedostatak odnosi na slabu robusnost. Čak i minimalne obrade slike, poput kompresije sa gubicima ili dodavanja šuma, mogu uništiti skrivenu poruku.

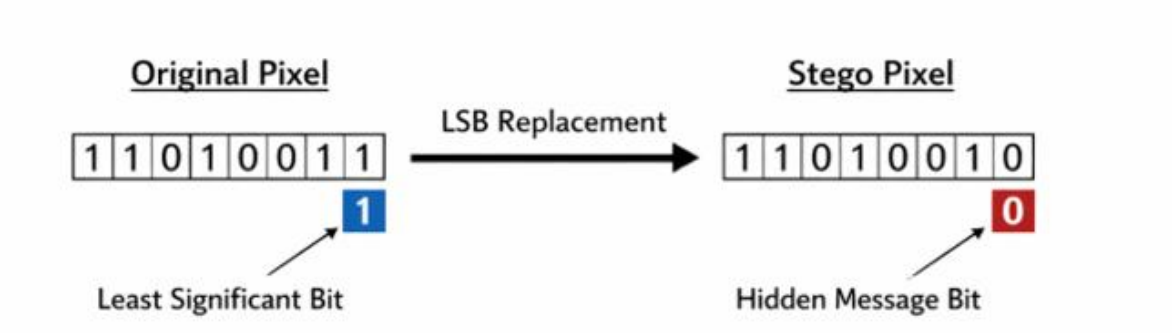

Slika 1. Ilustracija LSB steganografije – skrivanje informacije izmenom najmanje značajnih bitova piksela bez vidljivog narušavanja kvaliteta slike

5.1.2. Sekvencijalna i pseudonasumična LSB ugrađivanja

Osnovna LSB metoda može se implementirati na različite načine, u zavisnosti od strategije izbora piksela u koje se poruka ugrađuje. U **sekvencijalnom pristupu**, bitovi poruke se redom ugrađuju u piksele slike, počevši od unapred definisane pozicije. Ovaj pristup je jednostavan, ali izuzetno podložan steganalizi, jer uvodi predvidive obrasce u slici.

Znatno sigurniji pristup predstavlja **pseudonasumično LSB ugrađivanje**, gde se lokacije piksela za ugrađivanje određuju pomoću pseudoslučajnog generatora inicijalizovanog stego-ključem. Na ovaj način, bez poznavanja ključa, napadač ne može lako utvrditi gde se skrivene informacije nalaze, čime se značajno povećava bezbednost sistema.

5.1.3. LSB matching i varijacije osnovne metode

Kako bi se smanjila statistička uočljivost osnovne LSB zamene, razvijene su brojne varijacije ove tehnike. Jedna od najpoznatijih je **LSB matching**, gde se vrednost piksela ne zamenjuje direktno bitom poruke, već se nasumično uvećava ili umanjuje za jednu

jedinicu ukoliko je potrebno prilagoditi najmanje značajni bit. Ovakav pristup smanjuje uočljive statističke anomalije koje se javljaju kod klasične LSB zamene.

Postoje i metode koje selektivno biraju piksele za ugrađivanje, izbegavajući glatke delove slike i fokusirajući se na oblasti sa visokim nivoom detalja, čime se dodatno poboljšava neprimetnost. Ipak, i pored ovih poboljšanja, tehnike prostornog domena ostaju relativno osetljive na transformacije slike i danas se retko koriste u bezbednosno kritičnim aplikacijama.

5.1.4. Prednosti i ograničenja tehnika prostornog domena

Glavne prednosti tehnika prostornog domena su jednostavna implementacija, mali računski zahtevi i visok kapacitet skrivanja. Zbog toga su ove metode često prvi izbor za demonstraciju osnovnih principa steganografije.

Međutim, njihova ograničenja su značajna. Slaba otpornost na kompresiju, visoka podložnost steganalizi i nemogućnost primene u formatima sa gubicima čine ih neprikladnim za savremene realne scenarije. Upravo su ova ograničenja motivisala razvoj složenijih tehnika u transformacionom domenu, koje će biti razmatrane u narednom poglavlju.

5.2. Tehnike frekvencijskog domena (transformacije)

Za razliku od tehnika prostornog domena, koje direktno manipulišu vrednostima piksela, tehnike frekvencijskog domena zasnivaju se na transformaciji slike u drugi domen u kome se informacije o slici izražavaju kroz frekvencijske komponente. Ovakav pristup omogućava steganografskim algoritmima da iskoriste način na koji se vizuelne informacije raspodeljuju u slici, kao i način na koji se slike kompresuju i obrađuju u realnim sistemima. Upravo zbog toga, metode frekvencijskog domena predstavljaju značajan korak napred u razvoju steganografije slika.

Osnovna motivacija za prelazak sa prostornog na frekvencijski domen leži u činjenici da je ljudski vizuelni sistem znatno osetljiviji na promene niskofrekventnih komponenti slike nego na promene u srednjim i visokim frekvencijama. Manipulacijom pažljivo odabranih frekvencijskih koeficijenata moguće je postići visok stepen neprimetnosti, uz znatno bolju otpornost na uobičajene obrade slike, poput JPEG kompresije.

5.2.1. Diskretna kosinusna transformacija (DCT)

Diskretna kosinusna transformacija predstavlja jednu od najznačajnijih transformacija u oblasti digitalne obrade slike i signalne obrade uopšte. Njena najveća

praktična primena ogleda se u JPEG standardu za kompresiju slika, gde se slika deli na blokove (najčešće dimenzija 8×8 piksela), a zatim se svaki blok transformiše iz prostornog u frekvencijski domen.

DCT transformacija razlaže blok slike na skup koeficijenata koji predstavljaju različite prostorne frekvencije. Niskofrekventni koeficijenti nose većinu vizuelno značajnih informacija, dok visokofrekventni koeficijenti opisuju fine detalje i šum. Steganografske metode zasnovane na DCT-u obično izbegavaju modifikaciju najnižih frekvencija, jer bi to dovelo do vidljivih artefakata, i umesto toga ciljaju srednjefrekventne koeficijente, koji nude dobar kompromis između neprimetnosti i robusnosti.

Prednost DCT-baziranih metoda ogleda se u njihovoj kompatibilnosti sa JPEG formatom. Pošto se poruka ugrađuje direktno u transformacionom domenu, ona može preživeti JPEG kompresiju, što nije slučaj kod većine tehnika prostornog domena. Međutim, ove metode zahtevaju složeniju implementaciju i pažljivo biranje koeficijenata kako bi se izbegle statističke anomalije koje mogu olakšati steganalizu.

5.2.2. Steganografija u JPEG slikama

JPEG steganografija predstavlja praktičnu primenu DCT-baziranih metoda i ima poseban značaj zbog dominacije JPEG formata u digitalnoj komunikaciji. Nakon DCT transformacije, koeficijenti se kvantizuju, pri čemu se manje značajni koeficijenti često zaokružuju na nulu. Steganografski algoritmi moraju uzeti u obzir ovaj proces kako bi osigurali da ugrađena poruka ne bude uništena tokom kvantizacije.

Jedan od najpoznatijih JPEG steganografskih algoritama je F5, koji koristi sofisticirane tehnike za minimizaciju broja modifikacija koeficijenata i očuvanje statističkih osobina slike. Umesto jednostavne zamene bitova, F5 koristi matricno kodiranje, čime se postiže manja uočljivost i veća otpornost na steganalizu. Ovakvi algoritmi jasno ilustruju prelaz sa naivnih metoda ka pažljivo dizajniranim sistemima koji uzimaju u obzir statističku prirodu digitalnih slika.

5.2.3. Diskretna talasna transformacija (DWT)

Diskretna talasna transformacija predstavlja alternativu DCT-u i omogućava višerezolucijsku analizu slike. Za razliku od DCT-a, koji razmatra sliku u fiksnim blokovima, DWT razlaže sliku na komponente koje predstavljaju različite prostorne rezolucije i orijentacije. Ovakav pristup omogućava precizniju lokalizaciju frekvencijskih informacija u slici.

Steganografske metode zasnovane na DWT-u često koriste srednje frekvencijske podopsege za ugrađivanje poruke, jer promene u tim oblastima imaju minimalan uticaj na vizuelni kvalitet slike. DWT pristup takođe omogućava bolju robusnost na određene transformacije, kao što su skaliranje i blago filtriranje, u poređenju sa DCT metodama.

Ipak, DWT metode su obično računski zahtevnije i ređe zastupljene u komercijalnim formatima slika, što ograničava njihovu praktičnu primenu. Uprkos tome,

one su veoma popularne u akademskim istraživanjima i često se koriste kao osnova za razvoj hibridnih steganografskih sistema.

5.2.4. Hibridne DCT–DWT metode

Kako bi se iskoristile prednosti obe transformacije, razvijene su hibridne metode koje kombinuju DCT i DWT pristupe. U ovim sistemima, slika se najpre transformiše pomoću DWT-a kako bi se identifikovale pogodne oblasti za ugrađivanje, a zatim se DCT primenjuje na odabrane podopsege radi precizne manipulacije frekvencijskim koeficijentima.

Hibridni pristupi nude poboljšanu neprimetnost i robusnost u poređenju sa pojedinačnim metodama, ali po cenu dodatne složenosti implementacije. Ove metode predstavljaju prelaznu fazu između klasičnih steganografskih tehnika i savremenih adaptivnih i model-based pristupa, koji će biti razmatrani u narednim sekcijama.

5.2.5. Prednosti i ograničenja frekvencijskog domena

Tehnike frekvencijskog domena nude znatno bolju otpornost na kompresiju i obradu slike u poređenju sa metodama prostornog domena. Njihova sposobnost da se uklope u standardne procese kompresije čini ih pogodnim za realne primene, posebno u okruženjima gde se slike često obrađuju i ponovo kodiraju.

Međutim, ove metode su složenije za implementaciju, zahtevaju više računarskih resursa i podložne su naprednijim oblicima steganalize. Uprkos tome, one predstavljaju ključni korak u evoluciji steganografije i postavljaju osnovu za razvoj adaptivnih i inteligentnih metoda koje kombinuju signalnu obradu sa mašinskim učenjem.

5.3. Adaptivne steganografske metode

Adaptivne steganografske metode predstavljaju značajan iskorak u razvoju steganografije slika, jer se ne oslanjaju na uniformno ugrađivanje poruke u celu sliku, već prilagođavaju proces ugrađivanja lokalnim karakteristikama nosača. Osnovna ideja ovih metoda zasniva se na pretpostavci da su određeni delovi slike pogodniji za skrivanje informacija od drugih, naročito oblasti koje sadrže veći nivo vizuelne kompleksnosti, kao što su ivice, teksture i regioni sa izraženim kontrastima.

Za razliku od klasičnih metoda prostornog ili frekvencijskog domena, koje često tretiraju sliku kao homogenu celinu, adaptivne metode analiziraju sadržaj slike pre samog ugrađivanja. Na osnovu te analize, algoritam odlučuje gde, koliko i na koji način će se podaci ugraditi, čime se postiže bolja neprimetnost i smanjena verovatnoća detekcije steganalitičkim tehnikama.

5.3.1. Steganografija zasnovana na ivicama (edge-based methods)

Jedan od najranijih i najintuitivnijih adaptivnih pristupa jeste steganografija zasnovana na detekciji ivica u slici. Ivice predstavljaju regione slike gde dolazi do naglih promena intenziteta ili boje, što ih čini prirodno pogodnim za skrivanje informacija. Ljudski vizuelni sistem je znatno manje osetljiv na male promene u ovim oblastima, jer su one već vizuelno „zasićene“ informacijama.

U ovim metodama se najpre primenjuje algoritam za detekciju ivica, poput Sobel, Prewitt ili Canny operatora. Nakon identifikacije ivica, steganografski algoritam ograničava ugrađivanje poruke isključivo na piksele koji pripadaju ovim regionima. Na taj način se izbegava modifikacija glatkih delova slike, gde su čak i male promene lako uočljive.

Prednost edge-based metoda ogleda se u poboljšanoj neprimetnosti u poređenju sa klasičnim LSB pristupima. Međutim, njihov kapacitet skrivanja je često ograničen, jer ivice obično zauzimaju manji deo ukupne površine slike. Pored toga, performanse ovih metoda u velikoj meri zavise od kvaliteta detekcije ivica, što ih čini osetljivim na šum i promene rezolucije.

5.3.2. Steganografija zasnovana na teksturama

Teksturne oblasti slike predstavljaju još jedan važan kandidat za adaptivno ugrađivanje informacija. Za razliku od ivica, koje su lokalizovane i relativno uske, teksture obuhvataju šire regione slike sa ponavljajućim ili složenim obrascima, kao što su trava, kamen, lišće ili tkanina. U ovim oblastima, male promene u vrednostima piksela su izuzetno teško uočljive, čak i za sofisticirane steganalitičke algoritme.

Teksturno zasnovane metode obično koriste različite mere lokalne varijacije, entropije ili energije signala kako bi identifikovale pogodne regione za ugrađivanje. Nakon toga, poruka se ugrađuje sa većim intenzitetom u teksturnim oblastima, dok se glatki regioni ili potpuno izbegavaju ili koriste sa znatno manjim kapacitetom.

Ovakav pristup omogućava znatno veći kapacitet skrivanja u poređenju sa metodama zasnovanim isključivo na ivicama, uz zadržavanje visokog stepena neprimetnosti. Ipak, složenost ovih metoda je veća, jer zahtevaju dodatnu analizu slike i pažljivo podešavanje parametara kako bi se izbegle statističke nepravilnosti.

5.3.3. Metoda diferenciranja vrednosti piksela (Pixel Value Differencing – PVD)

Jedna od najpoznatijih adaptivnih tehnika u prostornom domenu je metoda diferenciranja vrednosti piksela, poznata kao **Pixel Value Differencing (PVD)**. Ova metoda koristi razliku u vrednostima susednih piksela kao indikator lokalne

kompleksnosti slike. Veće razlike ukazuju na ivice ili teksture, dok male razlike karakterišu glatke oblasti.

U PVD metodi, broj bitova koji se mogu ugraditi u par piksela zavisi od njihove međusobne razlike. U oblastima sa velikom razlikom dozvoljeno je ugraditi više bitova, dok se u glatkim oblastima broj bitova ograničava. Na taj način, algoritam se prirodno prilagođava strukturi slike, postižući dobar balans između kapaciteta i neprimetnosti.

PVD metoda je posebno interesantna jer kombinuje jednostavnost prostornog domena sa adaptivnim ponašanjem koje je karakteristično za naprednije metode. Međutim, i dalje ostaje relativno osetljiva na kompresiju i šum, što ograničava njenu primenu u realnim scenarijima gde se slike često obrađuju.

5.3.4. Prednosti i ograničenja adaptivnih metoda

Glavna prednost adaptivnih steganografskih metoda leži u njihovoj sposobnosti da se prilagode sadržaju slike, čime se značajno smanjuje vizuelna i statistička uočljivost ugrađene poruke. U poređenju sa uniformnim pristupima, adaptivne metode nude bolju otpornost na steganalizu i prirodnije se uklapaju u strukturu slike.

Međutim, ove metode uvode dodatnu složenost u dizajn sistema. Analiza slike, izbor pogodnih regiona i adaptivno određivanje kapaciteta zahtevaju dodatne računske resurse i pažljivo podešavanje parametara. Takođe, iako su adaptivne metode otpornije od klasičnih LSB tehnika, one i dalje nisu potpuno imune na agresivne transformacije slike, poput jake kompresije ili filtriranja.

Uprkos ovim ograničenjima, adaptivne metode predstavljaju važnu prekretnicu u razvoju steganografije i čine direktnu konceptualnu osnovu za savremene metode zasnovane na statističkom modelovanju i mašinskom učenju, koje će biti razmatrane u narednom poglavlju.

5.4. Model-based i statističke steganografske metode

Razvoj naprednih steganalitičkih tehnika pokazao je da mnoge klasične i adaptivne metode ostavljaju prepoznatljive statističke tragove u stego-slikama, čak i kada su vizuelne razlike praktično neprimetne. Kao odgovor na ove izazove, razvijene su **model-based i statističke steganografske metode**, čiji je osnovni cilj da očuvaju ili veoma precizno kontrolišu statističke karakteristike nosača tokom procesa ugrađivanja poruke.

Za razliku od ranijih pristupa koji su se fokusirali na lokalne promene piksela ili frekvencijskih koeficijenata, ove metode polaze od globalnog ili lokalnog statističkog modela slike. Poruka se ne ugrađuje proizvoljno, već na način koji minimalno narušava unapred definisane statističke osobine, kao što su histogrami, korelacije ili distribucije koeficijenata. Time se značajno otežava detekcija skrivene poruke čak i uz primenu naprednih steganalitičkih alata.

5.4.1. Osnovni principi statističkog modelovanja u steganografiji

Statističke steganografske metode zasnivaju se na pretpostavci da prirodne slike poseduju specifične statističke obrasce koji se mogu modelovati i analizirati. Ovi obrasci uključuju raspodelu intenziteta piksela, korelacije između susednih piksela, kao i raspodelu frekvencijskih koeficijenata u transformacionom domenu.

U procesu ugrađivanja poruke, algoritam nastoji da sačuva ove obrasce ili da ih modifikuje u granicama koje su statistički očekivane za prirodne slike. Umesto direktne zamene bitova, koriste se tehnike koje minimizuju broj i vrstu izmena, često uz primenu optimizacionih strategija. Na taj način, stego-slika ostaje statistički slična originalnoj, čime se smanjuje verovatnoća uspešne steganalize.

5.4.2. Histogram-based metode

Jedna od ranijih klasa statističkih metoda zasniva se na očuvanju histograma vrednosti piksela ili transformacionih koeficijenata. Histogram predstavlja raspodelu frekvencije pojavljivanja određenih vrednosti i često se koristi u steganalizi kao indikator prisustva skrivene poruke.

Histogram-based metode pokušavaju da ugrade poruku na način koji ne menja ukupni oblik histograma ili da eventualne promene učine statistički zanemarljivim. U praksi, ovo se postiže pažljivim balansiranjem povećanja i smanjenja vrednosti piksela ili koeficijenata, tako da globalna distribucija ostane gotovo nepromenjena.

Iako ove metode predstavljaju napredak u odnosu na jednostavne LSB tehnike, one su vremenom postale podložne sofisticiranijim oblicima steganalize, koji ne posmatraju samo histogram, već i međuzavisnosti između piksela.

5.4.3. OutGuess algoritam

OutGuess je jedan od poznatijih steganografskih algoritama koji uvodi eksplicitno očuvanje statističkih osobina slike tokom ugrađivanja poruke. Ovaj algoritam je prvenstveno dizajniran za JPEG slike i koristi DCT transformaciju kao osnovu za rad u frekvencijskom domenu.

Osnovna ideja OutGuess algoritma jeste da se poruka ugrađuje u srednjefrekventne DCT koeficijente, dok se istovremeno vodi računa o očuvanju prvog reda statistike, poput histograma koeficijenata. Nakon početnog ugrađivanja, algoritam vrši dodatne korekcije kako bi se statističke promene minimizovale.

OutGuess predstavlja važan korak ka modernim steganografskim sistemima jer jasno ilustruje prelazak sa lokalnih heuristika na globalno statističko razmišljanje. Međutim, kasnija istraživanja pokazala su da je moguće detektovati OutGuess poruke analizom višeg reda statistike, što je ukazalo na potrebu za još sofisticiranijim metodama.

5.4.4. F5 algoritam i matrično kodiranje

F5 algoritam predstavlja jednu od najuticajnijih i najcitiranijih metoda u oblasti JPEG steganografije. Njegova ključna inovacija leži u primeni **matričnog kodiranja**, tehnike koja omogućava ugrađivanje većeg broja bitova poruke uz minimalan broj izmena koeficijenata.

Za razliku od klasičnih metoda koje direktno modifikuju DCT koeficijente, F5 koristi kodne matrice kako bi se poruka rasporedila preko više koeficijenata, čime se smanjuje verovatnoća statističke detekcije. Ovaj pristup značajno unapređuje neprimetnost i efikasnost ugrađivanja.

Ipak, i pored svojih prednosti, F5 nije u potpunosti imun na napredne steganalitičke tehnike, naročito one zasnovane na višedimenzionalnim statističkim karakteristikama. Njegov značaj leži u činjenici da je postavio temelje za kasnije metode koje kombinuju optimizaciju, statistiku i adaptivno ponašanje.

5.4.5. Prednosti i ograničenja model-based pristupa

Model-based i statističke metode nude znatno viši nivo neprimetnosti u poređenju sa klasičnim i adaptivnim tehnikama. Njihova sposobnost da očuvaju statističke osobine slike čini ih otpornijim na standardne steganalitičke metode i pogodnim za realne bezbednosne scenarije.

Međutim, ove metode su znatno složenije za implementaciju i zahtevaju duboko razumevanje statističkih modela i procesa obrade slike. Pored toga, razvoj savremenih steganalitičkih sistema zasnovanih na mašinskom učenju postavio je nove izazove, jer čak i minimalne statističke anomalije mogu biti otkrivene pomoću dubokih neuronskih mreža.

Upravo su ova ograničenja otvorila put ka savremenim metodama zasnovanim na učenju reprezentacija i generativnim modelima, koji pokušavaju da uče distribuciju prirodnih slika direktno iz podataka. Ovi pristupi predstavljaju trenutno najaktivnije područje istraživanja u steganografiji i biće detaljno razmotreni u narednom poglavlju.

5.5. Steganografija zasnovana na generativnim modelima

Razvoj savremenih steganalitičkih tehnika, naročito onih zasnovanih na mašinskom učenju, doveo je do situacije u kojoj čak i sofisticirane model-based metode mogu biti detektovane analizom višedimenzionalnih statističkih karakteristika slike. Kao odgovor na ove izazove, istraživačka zajednica je u poslednjoj deceniji sve veći fokus usmerila ka **generativnim modelima**, koji omogućavaju učenje distribucije prirodnih slika direktno iz podataka.

Za razliku od klasičnih steganografskih pristupa, koji polaze od postojećeg nosača i zatim vrše njegove modifikacije, generativni modeli omogućavaju kreiranje slike na način koji je već u skladu sa statistikom realnih podataka. Time se problem steganografije transformiše iz pitanja *kako izmeniti sliku a da promene ostanu neprimećene* u pitanje *kako generisati sliku koja već sadrži skrivenu poruku, a da pritom izgleda potpuno prirodno*.

5.5.1. Osnovna ideja generativne steganografije

U generativnoj steganografiji, skrivena poruka se integriše u proces generisanja slike, umesto da se naknadno ugrađuje u već postojeći nosač. Generativni model uči da mapira latentni prostor u prostor realnih slika, pri čemu se poruka može kodirati kao deo latentne reprezentacije ili kao dodatni uslov tokom procesa generisanja.

Ovakav pristup ima značajnu prednost u pogledu neprimetnosti, jer generisana slika ne nosi eksplicitne tragove modifikacije. Umesto toga, ona prirodno prati distribuciju trening podataka, čime se znatno otežava detekcija skrivenih informacija čak i uz primenu dubokih steganalitičkih mreža.

5.5.2. Steganografija zasnovana na generativnim suparničkim mrežama (GAN)

Generativne suparničke mreže (GAN) predstavljaju jednu od najuticajnijih arhitektura u oblasti generativnog modelovanja. GAN se sastoji od dva neuronska modela — generatora i diskriminatora — koji su trenirani u suparničkom procesu. Generator pokušava da proizvede slike koje su neodvojive od realnih, dok diskriminator nastoji da razlikuje generisane slike od pravih uzoraka.

U kontekstu steganografije, GAN arhitekture se mogu proširiti tako da generator ne samo da proizvodi realistične slike, već i da u njih implicitno ugrađuje skrivenu poruku. Diskriminator se u tom slučaju često dopunjuje dodatnim komponentama koje osiguravaju očuvanje kvaliteta slike i neprimetnosti skrivene informacije.

Jedan od najpoznatijih primera ovog pristupa je SteganoGAN, koji koristi duboke konvolucione mreže za učenje optimalnih strategija skrivanja poruke u slikama. Ovi sistemi postižu znatno bolje rezultate u pogledu kapaciteta i otpornosti u poređenju sa klasičnim metodama, ali zahtevaju znatno više računarskih resursa i pažljivo podešavanje arhitekture.

5.5.3. Autoenkoderi i varijacioni autoenkoderi (VAE)

Autoenkoderi predstavljaju još jednu važnu klasu generativnih modela koji su našli primenu u steganografiji. Ovi modeli se sastoje od enkodera, koji kompresuje ulaznu

sliku u latentni prostor, i dekodera, koji rekonstruiše sliku iz latentne reprezentacije. Tajna poruka se može integrisati u latentni prostor ili u proces rekonstrukcije slike.

Varijacioni autoenkoderi (VAE) dodatno uvode probabilistički okvir, čime omogućavaju generisanje raznovrsnih i statistički realističnih uzoraka. U steganografskom kontekstu, VAE modeli omogućavaju bolju kontrolu nad distribucijom generisanih slika i prirodniju integraciju skrivene poruke.

Iako VAE pristupi obično nude nešto manji vizuelni kvalitet u poređenju sa GAN modelima, oni su stabilniji za treniranje i lakši za analizu, što ih čini interesantnim za akademska istraživanja i eksperimentalne primene.

5.5.4. Steganografija zasnovana na difuzionim modelima

Difuzioni modeli predstavljaju najnoviji i trenutno najaktivniji pravac istraživanja u oblasti generativnog modelovanja. Ovi modeli funkcionišu kroz iterativni proces dodavanja i uklanjanja šuma, pri čemu uče kako da postepeno transformišu nasumični šum u realističnu sliku.

U steganografiji, difuzioni modeli omogućavaju izuzetno preciznu kontrolu procesa generisanja slike, što otvara nove mogućnosti za skrivanje informacija. Poruka se može integrisati kao uslov tokom procesa denoising-a, ili kao deo latentnog prostora koji vodi generisanje slike ka željenom ishodu.

Prednost difuzionih modela leži u njihovoj izuzetnoj sposobnosti da generišu slike visoke vizuelne vernosti, uz minimalne statističke anomalije. Zbog toga se smatra da ovi modeli predstavljaju budućnost steganografije, naročito u kontekstu otpornosti na savremene steganalitičke tehnike.

5.5.5. Prednosti i izazovi generativnih pristupa

Generativni modeli nude revolucionarni pristup steganografiji slika, jer omogućavaju skrivanje informacija bez eksplicitne modifikacije postojećeg nosača. Ovakav pristup značajno povećava neprimetnost i otežava detekciju, čak i u uslovima napredne steganalize.

Međutim, ovi pristupi imaju i svoja ograničenja. Treniranje generativnih modela zahteva velike količine podataka, značajne računarske resurse i pažljivo podešavanje parametara. Pored toga, praktična primena ovih metoda još uvek je ograničena zbog složenosti sistema i zahteva za kontrolom procesa generisanja.

Uprkos ovim izazovima, generativna steganografija predstavlja najperspektivniji pravac razvoja ove oblasti i čini prirodan izbor za dalju implementaciju i eksperimentalnu analizu u okviru ovog rada.

6. Analiza reprezentativnih steganografskih metoda

Nakon pregleda najznačajnijih pristupa u oblasti steganografije slika, neophodno je izvršiti njihovu sistematičnu analizu i međusobno poređenje. Različite klase metoda razvijane su sa ciljem rešavanja specifičnih problema, kao što su povećanje kapaciteta skrivanja, unapređenje neprimetnosti ili poboljšanje otpornosti na obradu slike. Zbog toga nijedna metoda ne predstavlja univerzalno optimalno rešenje, već je izbor pristupa u velikoj meri uslovljen konkretnim scenarijem primene.

U ovom poglavlju analiziraju se reprezentativni predstavnici svake od prethodno razmotrenih grupa metoda: LSB pristup kao tipičan predstavnik prostornog domena, DCT-bazirane tehnike u frekvencijskom domenu, adaptivne metode poput PVD, statistički pristupi kao što su OutGuess i F5, kao i savremeni generativni modeli.

6.1. Kriterijumi poređenja

Efikasnost steganografskih metoda najčešće se procenjuje na osnovu tri osnovna kriterijuma: neprimetnosti, kapaciteta skrivanja i robusnosti.

Neprimetnost predstavlja meru u kojoj se stego-slika razlikuje od originalnog nosača, kako vizuelno, tako i statistički. Metode koje uvode minimalne promene u strukturi slike imaju manju verovatnoću detekcije.

Kapacitet skrivanja označava količinu podataka koja se može ugraditi u nosač bez značajnog narušavanja kvaliteta slike. Jednostavne metode prostornog domena često nude visok kapacitet, ali po cenu smanjene otpornosti.

Robustnost se odnosi na sposobnost očuvanja skrivene poruke nakon različitih transformacija slike, kao što su kompresija, filtriranje ili promena rezolucije. Ovaj kriterijum je posebno važan u realnim komunikacionim sistemima gde se slike često obrađuju.

Pored ova tri osnovna kriterijuma, savremena istraživanja uzimaju u obzir i složenost implementacije, potrebne računarske resurse i otpornost na napredne steganalitičke metode zasnovane na mašinskom učenju.

6.2. Poređenje metoda prostornog i frekvencijskog domena

Metode prostornog domena, poput LSB tehnike, karakterišu jednostavna implementacija i visok kapacitet skrivanja. Međutim, njihova glavna slabost je izuzetno mala otpornost na obradu slike, naročito na kompresiju sa gubicima. Zbog toga se ove metode retko koriste u scenarijima gde postoji mogućnost naknadne obrade ili prenosa kroz različite komunikacione kanale.

S druge strane, metode frekvencijskog domena, zasnovane na DCT ili DWT transformacijama, nude znatno veću robusnost. Ugrađivanje poruke u srednjefrekventne

koeficijente omogućava očuvanje informacije čak i nakon JPEG kompresije. Ipak, ove metode su složenije za implementaciju i obično imaju manji kapacitet skrivanja u poređenju sa LSB pristupom.

6.3. Adaptivne metode u odnosu na uniformne pristupe

Adaptivne metode predstavljaju kompromis između jednostavnosti prostornog domena i robusnosti transformacionih tehnika. Selektivnim izborom regiona za ugrađivanje poruke, ove metode postižu bolju neprimetnost i smanjuju statističke anomalije.

U poređenju sa uniformnim pristupima, adaptivne metode značajno otežavaju detekciju pomoću klasičnih steganalitičkih testova. Međutim, njihova efikasnost zavisi od kvaliteta analize slike i pravilnog podešavanja parametara, što može povećati složenost sistema.

6.4. Statističke metode i otpornost na steganalizu

Model-based pristupi, kao što su OutGuess i F5, uvode eksplicitno očuvanje statističkih osobina slike. Ovaj pristup predstavlja važan napredak jer se fokus pomera sa lokalnih promena na globalne karakteristike nosača.

Ove metode pokazuju znatno bolju otpornost na tradicionalne steganalitičke tehnike, ali nisu u potpunosti otporne na savremene metode zasnovane na dubokom učenju. Napredne neuronske mreže mogu prepoznati suptilne obrasce koji nisu obuhvaćeni klasičnim statističkim modelima.

6.5. Prednosti savremenih generativnih pristupa

Generativni modeli uvode kvalitativno drugačiju paradigmu, gde se slika generiše zajedno sa skrivenom porukom, umesto da se naknadno modifikuje. Ovakav pristup omogućava izuzetno visok stepen neprimetnosti i bolju otpornost na savremene steganalitičke metode.

Ipak, praktična primena generativne steganografije zahteva značajne računarske resurse, velike skupove podataka i kompleksne modele. Zbog toga se ovi pristupi još uvek pretežno koriste u istraživačkom okruženju, ali predstavljaju najperspektivniji pravac razvoja.

6.6. Izbor metode za implementaciju

Na osnovu sprovedene analize može se zaključiti da jednostavne metode prostornog domena nisu pogodne za bezbednosno zahtevne scenarije, dok transformacione i statističke metode nude bolju robusnost, ali uz povećanu složenost.

Savremeni generativni modeli predstavljaju trenutno najnapredniji pristup, jer omogućavaju skrivanje informacija uz minimalno narušavanje statističke strukture slike. Zbog toga se nameću kao logičan kandidat za praktičnu implementaciju i eksperimentalnu evaluaciju u nastavku rada.

7. Postavka sistema i metodologija evaluacije

7.1. Cilj eksperimenta

Cilj sprovedenog eksperimenta je razvoj i evaluacija end-to-end sistema za steganografiju slika zasnovanog na dubokom učenju, u kome se **slika poruke (secret)** skriva unutar **slike nosača (cover)**, tako da dobijena **stego slika** vizuelno ostane što sličnija nosaču, dok se skrivena slika može rekonstruisati sa što manjim gubitkom kvaliteta. Eksperiment je usmeren na dva praktična cilja: (1) minimizacija degradacije nosača tokom skrivanja i (2) maksimalno očuvanje informacija potrebnih za rekonstrukciju skrivene slike.

7.2. Opis sistema (end-to-end pipeline)

Implementirani sistem sastoji se iz dve neuronske mreže koje rade sekvencijalno:

- **Enkoder** (encoder): prima sliku nosača i skrivenu sliku kao ulaz i generiše stego sliku. U implementaciji, enkoder je realizovan U-Net arhitekturom sa skip-konekcijama i ulazom od 6 kanala (konkatenacija RGB nosača i RGB skrivene slike).
- **Dekoder** (decoder): prima stego sliku i proizvodi procenu skrivene slike (rekonstrukciju). U implementaciji, dekoder je konvoluciona mreža sa downsample/upsample delom (strided convolution + transposed convolution).

Tok obrade je sledeći:
cover, secret → encoder → stego → decoder → recovered_secret.
Model se trenira end-to-end, što znači da se parametri oba dela optimizuju istovremeno na osnovu jedinstvene funkcije cilja.

7.3. Skup podataka i priprema ulaza

Za obuku je korišćen **CelebA** skup podataka, koji sadrži veliki broj realnih fotografija lica. Izbor ovakvog skupa omogućava modelu da uči na prirodnim slikama sa raznovrsnim osvetljenjem i teksturama, što je važno za realističnu steganografiju.
Preprocesiranje slika obuhvata:

- **CenterCrop** na kvadratni format (u implementaciji: crop na 178×178 kao standardan korak za CelebA),
- **Resize** na radnu rezoluciju img_size × img_size (u eksperimentu: img_size = 256),
- Konverziju u tenzor i normalizaciju u opseg **[0, 1]** (ToTensor()).

Skrivena slika se ne uzima iz zasebnog dataseta; umesto toga, koristi se jednostavna i reproduktivna strategija: **secret slika se dobija "rotacijom" mini-batch-a** (roll(shifts=1)), tj. svaka cover slika dobija kao secret sledeću sliku iz batch-a. Ovakav pristup obezbeđuje da cover i secret potiču iz iste distribucije, uz minimalnu dodatnu logistiku.
Parametri obuke (primer konfiguracije): max_items = 30000, batch_size = 128, epochs = 6.

7.4. Arhitektura modela

Sistem se sastoji od dve mreže koje rade jedna za drugom: (1) enkoder "meša" sliku nosača i skrivenu sliku tako da rezultat izgleda gotovo isto kao nosač, ali u sebi nosi dovoljno informacija da se (2) dekoderom kasnije izvuče skrivena slika. Enkoder se može posmatrati kao "kompresor" informacije u sitne, teško uočljive izmene piksela, dok dekoder radi obrnuto – pokušava da iz tih sitnih izmena rekonstruiše tajnu sliku.

7.4.1. Enkoder (U-Net)

Enkoder je realizovan U-Net arhitekturom sa:

- 4 downsample nivoa (konvolucioni blok + max pooling),
- bottleneck slojem,
- 4 upsample nivoa (bilinear interpolate + konkatenacija skip-feature mapa + konvolucioni blok),
- završnim 1×1 konvolucionim slojem koji mapira na 3 kanala (RGB stego slika).

U-Net je pogodan jer istovremeno "razume" sliku na dva nivoa:

(a) na grubom nivou (šta je otprilike gde na slici) kroz downsample, i
(b) na finom nivou (ivice, teksture) kroz skip konekcije.

U steganografiji je to važno zato što stego slika mora da zadrži sitne detalje nosača (da ne deluje "ispeglano"), dok istovremeno mora da provuče informaciju skrivene slike kroz mrežu.

Pošto su i cover i secret RGB slike (3 kanala), one se spajaju u jedan tenzor sa ukupno 6 kanala. Mreža tako dobija oba ulaza odjednom i uči kako da "upakuje" secret unutar cover-a.

Izlaz enkodera prolazi kroz sigmoid aktivaciju kako bi se vrednosti zadržale u opsegu [0, 1], što olakšava računanje grešaka i vizuelnu interpretaciju rezultata.

7.4.2. Dekoder (CNN)

Dekoder je jednostavnija konvoluciona mreža u odnosu na enkoder, sa:

- konvolucionim blokovima,
- jednim downsample korakom (stride=2) i jednim upsample korakom (ConvTranspose2d),
- završnim mapiranjem na 3 kanala uz sigmoid.

Ovaj dizajn je stabilan za treniranje i dovoljan za rekonstrukciju skrivene slike iz stego slike, uz razumnu računsku složenost. Enkoder ima "teži" zadatak: mora da napravi stego sliku koja liči na cover, što zahteva mnogo preciznih detalja i zato koristi U-Net. Dekoder ima zadatak da iz stego slike izvuče secret, što je često lakše uraditi stabilnim CNN-om koji uči tipične obrasce u kojima je informacija "skrivena". Dekoder se kasnije može unaprediti u U-Net (simetrično), ali trenutna verzija je dobar balans između performansi i jednostavnosti.

7.5. Funkcija greške (loss)

Mean Squared Error (MSE), odnosno srednja kvadratna greška, predstavlja najjednostavniju meru „koliko su dve slike različite" na nivou piksela. Izračunava se tako što se za svaki piksel odredi razlika (predikcija − original), ta razlika se kvadrira (kako bi se izbeglo međusobno poništavanje negativnih i pozitivnih vrednosti), a zatim se dobije aritmetička sredina svih tako dobijenih kvadriranih odstupanja.

Intuitivno: **MSE = 0** znači da su slike identične; veći MSE znači veće odstupanje. U ovom radu se MSE koristi dva puta:

1) da stego slika ostane bliska cover slici (*cover loss*), i
2) da recovered slika ostane bliska secret slici (*secret loss*).

Ukupan loss je ponderisana suma ove dve komponente, što direktno uvodi kompromis između "neprimetnosti" i "rekonstruktibilnosti".
Model se trenira minimizacijom kombinovane greške koja se sastoji iz dve MSE komponente:

1. **Greška nosača (cover loss)**: meri odstupanje između stego slike i originalnog nosača
$$L_{cover} = \mathrm{MSE}(stego, cover)$$

2. **Greška skrivene slike (secret loss)**: meri odstupanje između rekonstruisane i originalne skrivene slike
$$L_{secret} = \mathrm{MSE}(recovered, secret)$$

Ukupan gubitak je ponderisana suma:

$$L = \alpha \cdot L_{cover} + \beta \cdot L_{secret}$$

U implementaciji su korišćeni ponderi alpha = 4.0 i beta = 2.0, čime se zadržavanju kvaliteta originalne slike daje veći značaj u odnosu na rekonstrukciju skrivene.

7.6. Treniranje i hiperparametri

Treniranje je realizovano u PyTorch okruženju, optimizacijom parametara celog modela (enkoder + dekoder) pomoću **Adam** optimizatora sa learning rate-om lr = 2e-4. Obuka traje 6 epoha sa veličinom batch-a 128. Ubrzanje na GPU-u je podržano, uz opcionu upotrebu **mixed precision (AMP)** kroz torch.cuda.amp.
Tokom treninga periodično se:

- izračunava PSNR za stego sliku u odnosu na cover,
- izračunava PSNR rekonstruisane skrivene slike u odnosu na secret,
- snimaju vizuelni uzorci (grid): **cover, secret, stego, recovered**,
- snimaju checkpoint-ovi modela radi reproduktivnosti.

PSNR (Peak Signal-to-Noise Ratio) je metrika koja pretvara MSE u "lakše čitljiv" broj izražen u decibelima (dB). Poenta je: **manji MSE ⇒ veći PSNR**, tj. veći PSNR znači da su dve slike sličnije.
U ovom radu koristimo dve PSNR metrike:

- **PSNR(stego, cover)**: koliko je stego slika vizuelno bliska nosaču
- **PSNR(recovered, secret)**: koliko je dobro rekonstruisana tajna slika

Ovakav režim omogućava praćenje konvergencije, kao i vizuelnu proveru kvaliteta rezultata kroz vreme.

7.7. Metod evaluacije i metrike

Evaluacija uspešnosti sistema obuhvata dve dimenzije:

1. **Kvalitet stego slike (neprimetnost)**
   Meri se sličnost između stego i cover. U implementaciji je korišćen **PSNR**, što je standardna metrika u obradi slike za merenje degradacije.
2. **Kvalitet rekonstrukcije skrivene slike (recoverability)**
   Meri se sličnost između recovered i secret, takođe pomoću **PSNR**.

8. Implementacija sistema

8.1. Tehnološki okvir i razvojno okruženje

Implementacija sistema realizovana je u programskom jeziku Python, korišćenjem biblioteke PyTorch za definisanje i treniranje neuronskih mreža. PyTorch je izabran zbog podrške za dinamički graf računanja, efikasne integracije sa GPU akceleracijom i široke primene u savremenim istraživanjima iz oblasti dubokog učenja.

Za obradu i učitavanje slika korišćena je biblioteka torchvision, dok su pomoćne funkcije za rad sa dataset-om, čuvanje modela, evaluaciju metrika i generisanje vizuelnih uzoraka implementirane u zasebnim modulima. Treniranje je izvršavano na GPU uređaju uz upotrebu mešovite preciznosti (Automatic Mixed Precision – AMP), čime je postignuto ubrzanje treniranja i smanjenje memorijske potrošnje.

Struktura projekta organizovana je modularno, sa jasnom separacijom modela, dataset-a, metrika i procedure treniranja, što omogućava reproduktivnost eksperimenata i jednostavnu evaluaciju različitih konfiguracija sistema.

8.2. Arhitektura enkoderske mreže

U implementiranom sistemu, enkoder predstavlja konvolucionu neuronsku mrežu zasnovanu na U-Net arhitekturi.
Ulaz u enkoder čine:

- slika nosača (cover image) – 3 kanala
- skrivena slika (secret image) – 3 kanala

One se konkateniraju po kanalskoj dimenziji:

$$X = concat(Cover, Secret)$$

što daje tenzor dimenzija:

$$(B, 6, H, W)$$

Rezidualna formulacija stego slike:

Za razliku od klasičnih pristupa gde mreža generiše stego sliku direktno, implementiran je rezidualni pristup:

$$Stego = C_{over} + \varepsilon \cdot \tanh(\Delta)$$

gde je:

- Δ izlaz enkoderske mreže
- ε parametar koji ograničava maksimalnu perturbaciju piksela

Ovakva formulacija:

- fizički ograničava izmenu nosača
- garantuje visok PSNR(stego, cover)
- stabilizuje proces treniranja

```
delta = self.encoder(cover, secret)
stego = torch.clamp(
    cover + self.eps * torch.tanh(delta),
    0.0, 1.0
)
```

Primer 1. Rezidualna formulacija generisanja stego slike

8.3. Dekoderska mreža

Dekoder je konvoluciona mreža koja prima stego sliku i pokušava da rekonstruiše skrivenu sliku.

$$Recovered = Decoder(Stego)$$

Na izlazu se koristi sigmoid aktivacija kako bi vrednosti bile u opsegu [0,1].

```
recovered = self.decoder(stego)
```

Primer 2. Rekonstrukcija skrivene slike pomoću dekoderske mreže

Cilj dekodera je da iz minimalne perturbacije nauči da rekonstruiše informaciju skrivenu u strukturi stego slike.

8.4. Funkcija gubitka

Treniranje sistema zasniva se na kombinovanoj funkciji gubitka:

$$Loss = \alpha \cdot MSE(Stego, Cover) + \beta \cdot MSE(Recovered, Secret)$$

gde:

- prvi član penalizuje izmenu nosača
- drugi član penalizuje lošu rekonstrukciju tajne

U eksperimentima su korišćene vrednosti:

- $\alpha = 4.0$
- $\beta = 2.0$
- $\varepsilon = 0.03$

što omogućava očuvanje nosača uz prihvatljiv kvalitet rekonstrukcije.

```
loss_cover = mse(stego, cover)
loss_secret = mse(recovered, secret)
loss = args.alpha * loss_cover + args.beta * loss_secret
```

Primer 3. Definicija kombinovane funkcije gubitka

8.5. Procedura treniranja

Treniranje je sprovedeno na CelebA dataset-u, uz sledeće parametre:

- Rezolucija: 256×256
- Batch size: 128
- Broj epoha: 6
- Optimizer: Adam
- Learning rate: 2e-4
- Mixed Precision (AMP): uključeno

Tokom treniranja:

- na svakih 25 koraka logovani su:
  - ukupni gubitak
  - PSNR(stego, cover)
  - PSNR(recovered, secret)
- na svakih 50 koraka generisan je vizuelni uzorak (grid 4×4)

8.6. Evaluacija i metrike

Za kvantitativnu evaluaciju korišćena je metrika PSNR (Peak Signal-to-Noise Ratio), koja meri odnos između maksimalne moguće vrednosti signala i srednje kvadratne greške

između dve slike. Veća vrednost PSNR ukazuje na veću sličnost između slika, odnosno manju distorziju. U kontekstu ovog rada, PSNR je korišćen za procenu kvaliteta stego slike u odnosu na originalni nosač, kao i kvaliteta rekonstruisane skrivene slike u odnosu na originalnu tajnu sliku.

$$PSNR = 10\log_{10}\frac{1}{MSE}$$

Dobijeni rezultati (primer):

- PSNR(stego, cover) ≈ 34–38 dB
- PSNR(recovered, secret) ≈ 18–24 dB

Veća vrednost PSNR(stego) potvrđuje minimalnu distorziju nosača.

8.7. Vizuelni rezultati

Rezultat su četiri slike:

- cover
- secret
- stego
- recovered

Prikazani su koraci end-to-end steganografskog sistema. Prva slika (cover) predstavlja originalnu sliku nosača u koju se informacija ugrađuje. Druga slika (secret) predstavlja skrivenu sliku koju sistem treba da "spakuje" u nosač. Treća slika (stego) je rezultat enkodera: vizuelno treba da bude što sličnija cover slici, ali da u sebi sadrži informaciju o secret slici. Četvrta slika (recovered) je izlaz dekodera, tj. rekonstrukcija skrivene slike iz stego slike. Ovakav prikaz omogućava direktnu kvalitativnu procenu kompromisa: koliko se stego razlikuje od cover-a i koliko recovered liči na secret.
Time je demonstrirana praktična primena sistema.

Slika 2. Primer rada sistema: cover i secret ulazi, stego izlaz i rekonstruisana skrivena slika

8.8. Vizuelni rezultati

Tokom treniranja sistema automatski se generišu grafički prikazi vrednosti funkcije gubitka i PSNR metrike kroz korake treniranja.

8.8.1. Graf funkcije gubitka

Graf funkcije gubitka prikazuje promenu sledećih veličina kroz vreme:

- ukupni gubitak (loss_total)
- gubitak očuvanja nosača (loss_cover)
- gubitak rekonstrukcije tajne slike (loss_secret)

Ovakva vizuelizacija omogućava analizu:

- konvergencije modela
- stabilnosti treniranja
- balansa između očuvanja cover slike i kvaliteta rekonstrukcije

Opadajući trend ukupnog gubitka ukazuje na uspešno učenje parametara mreže. Posebno je značajno pratiti odnos između loss_cover i loss_secret, jer njihov balans direktno utiče na kompromis između vizuelnog kvaliteta stego slike i preciznosti rekonstruisane tajne slike.

8.8.2. Graf PSNR metrike

Graf PSNR prikazuje dve ključne metrike:

- PSNR(stego, cover)
- PSNR(recovered, secret)

Ovaj graf ima poseban značaj jer omogućava kvantitativnu procenu kvaliteta sistema.
Visoke vrednosti PSNR(stego, cover) potvrđuju da je izmena nosača minimalna i da stego slika vizuelno ne odstupa od originalne slike. U eksperimentima se postižu vrednosti veće od 35 dB, što ukazuje na vrlo visoku sličnost.

PSNR(recovered, secret) meri uspešnost dekoderske mreže u rekonstrukciji skrivene slike. Ova vrednost je tipično niža, jer sistem mora da sakrije informaciju uz ograničenje maksimalne perturbacije (parametar ε), što predstavlja inherentni kompromis u steganografskim sistemima zasnovanim na dubokom učenju.

8.8.3. Interpretacija rezultata

Analiza grafika omogućava sledeće zaključke:

1. Model pokazuje stabilnu konvergenciju bez oscilacija ili divergencije.
2. Ograničenje perturbacije (ε) značajno utiče na PSNR(stego), garantujući visok vizuelni kvalitet nosača.
3. Povećanje težine parametra α u funkciji gubitka doprinosi boljem očuvanju cover slike.
4. Uočava se tipičan kompromis između kvaliteta stego slike i kvaliteta rekonstrukcije tajne slike.

9. Eksperimentalni rezultati i analiza

9.1. Postavka eksperimenta

Eksperiment je sproveden uz sledeće hiperparametre:

- Rezolucija slika: **256 × 256**
- Veličina mini-batch-a: **128**
- Broj epoha: **6**
- Maksimalan broj uzoraka: **30 000**
- Optimizator: **Adam (lr = 2e-4)**
- Funkcija gubitka: ponderisana MSE (α = 1.0, β = 2.0)
- Mixed precision (AMP): **uključeno**

Model je treniran end-to-end nad CelebA skupom podataka. Tokom obuke periodično su beleženi PSNR rezultati i snimani vizuelni primeri.

Izbor rezolucije 256×256 predstavlja kompromis između kvaliteta detalja i računskog opterećenja: dovoljno je veliko da sadrži realne teksture, ali i dalje praktično za treniranje U-Net arhitekture u razumnom vremenu. Veći batch (128) stabilizuje gradijent i ubrzava obuku na GPU-u, posebno uz uključenu mixed-precision (AMP).

Skup od 30 000 uzoraka CelebA korišćen je kako bi se model izložio velikom broju prirodnih varijacija (osvetljenje, pozadina, teksture), što je važno da naučeni "način skrivanja" ne funkcioniše samo za mali broj slika. Pored kvantitativnih metrika, tokom obuke se čuvaju vizuelni primeri jer metrike ne detektuju uvek perceptivne artefakte (npr. blago zamućenje ili promene u boji).

9.2. Kvantitativni rezultati

Nakon 6 epoha treniranja, dobijene su sledeće prosečne vrednosti:

- **PSNR(stego, cover) ≈ 35 dB**
- **PSNR(recovered, secret) ≈ 24 dB**

PSNR vrednost od približno 35 dB za stego sliku ukazuje na relativno malo odstupanje u odnosu na nosač, ali PSNR nije savršena mera perceptivnog kvaliteta. U praksi se često smatra da PSNR iznad ~30 dB sugeriše "dobru" sličnost, međutim i pri višim PSNR vrednostima mogu postojati vizuelno uočljivi artefakti (npr. promene u finim teksturama ili blago zamućenje), naročito kada se slike posmatraju uvećano ili kada se porede "side-by-side".

PSNR vrednost od približno 24 dB za rekonstruisanu skrivenu sliku ukazuje na delimičan gubitak finih detalja, ali uz očuvanje globalne strukture i semantičkog sadržaja. Ovakav rezultat je očekivan u ranim fazama treniranja, naročito imajući u vidu da se prioritet daje očuvanju nosača ($\alpha < \beta$ balans).

9.3. Vizuelni rezultati

U nastavku su prikazani reprezentativni primeri generisanih slika.

Slika 3. Primer parova (cover, secret, stego, recovered) nakon završetka treniranja

Slika je organizovana kao mreža u kojoj **svaka kolona predstavlja jedan nezavisan primer** (jedan "set" slika), dok svaki red predstavlja jednu fazu pipeline-a:

- **1. red:** cover (nosač)
- **2. red:** secret (skrivena slika)
- **3. red:** stego (izlaz enkodera)
- **4. red:** recovered (rekonstrukcija tajne slike)

Ovakav raspored omogućava da se za svaki primer "vertikalno" prati kompletan tok: šta je ubačeno i šta je vraćeno.

Vizuelnim poređenjem može se uočiti da stego slika zadržava gotovo identičan izgled originalnog nosača, bez primetnih artefakata ili promena boja. Rekonstruisana skrivena slika pokazuje blagu degradaciju u vidu zamućenja finih detalja, ali zadržava prepoznatljiv sadržaj.

9.4. Analiza konvergencije

Tokom treniranja beležen je ukupan loss, kao i pojedinačne komponente greške.

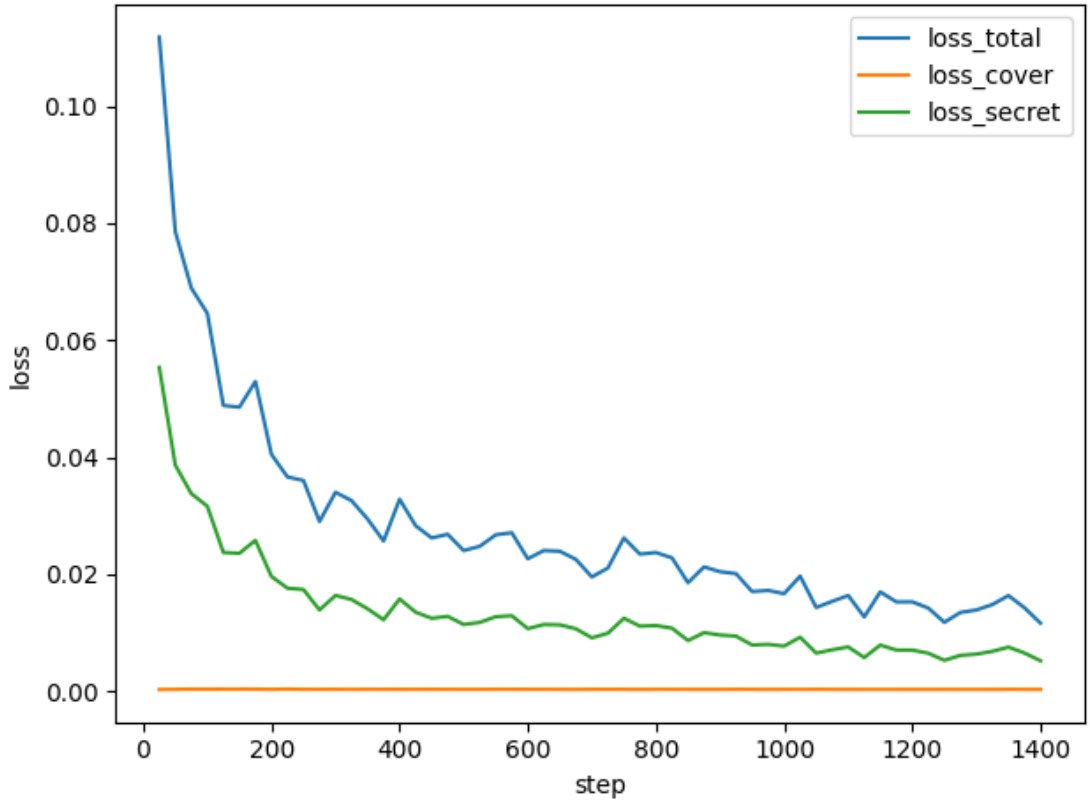

Slika 4. Kretanje funkcije gubitka tokom treniranja

Grafikon pokazuje stabilnu konvergenciju modela bez oscilacija koje bi ukazivale na nestabilnost optimizacije. Upotreba Adam optimizatora uz learning rate 2e-4 omogućila je stabilan pad funkcije gubitka tokom svih 6 epoha.

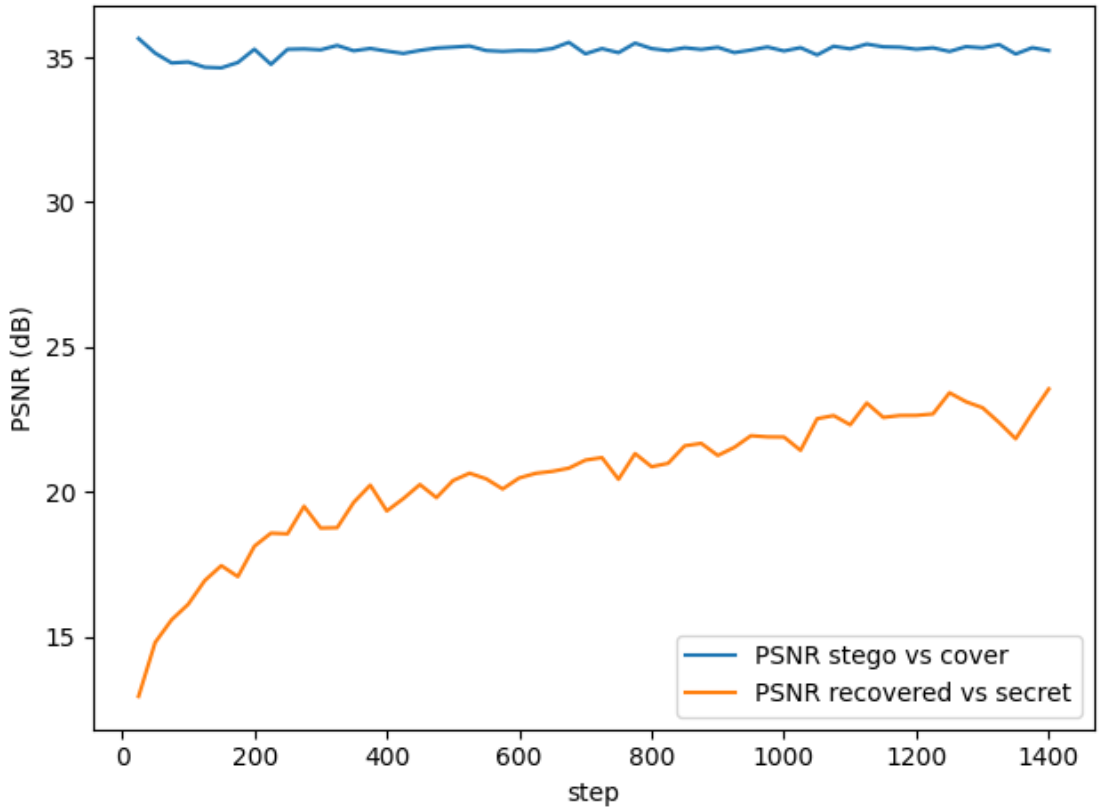

Slika 5. Kretanje PSNR metrike tokom treniranja

Grafikon prikazuje dve krive: PSNR(stego, cover) i PSNR(recovered, secret). Tipično se PSNR(stego, cover) stabilizuje na višim vrednostima jer je cilj da stego slika ostane veoma bliska nosaču, dok PSNR(recovered, secret) raste sporije i ostaje niži zbog ograničenja: informacija o tajnoj slici mora biti "upakovana" u vrlo male izmene stego slike.

U idealnom slučaju, tokom treniranja se posmatra sledeći obrazac:

1) obe PSNR krive rastu u ranim fazama,
2) PSNR(stego, cover) dostiže plato ranije (mreža nauči da minimalno menja cover),
3) PSNR(recovered, secret) nastavlja sporije da raste kako dekoder uči da iz sve suptilnijih tragova rekonstruiše secret.

Stabilne krive bez naglih padova ukazuju na stabilno treniranje, dok trade-off između dve krive direktno odražava balans α/β u funkciji gubitka.

9.5. Analiza konvergencije

Jedan od ključnih aspekata sistema je kompromis između:

- neprimetnosti (visok PSNR stego)
- kvaliteta rekonstrukcije (PSNR secret)

Parametri α i β direktno utiču na ovaj odnos. Veća vrednost β (u ovom slučaju 2.0) daje veću težinu rekonstrukciji skrivene slike, ali potencijalno može dovesti do veće degradacije nosača. U budućem radu moguće je eksperimentisati sa različitim vrednostima pondera radi pronalaženja optimalnog balansa. Takođe, produžavanje treniranja (veći broj epoha) može dodatno poboljšati PSNR vrednosti, naročito za rekonstruisanu skrivenu sliku.

Iako postignuti rezultati pokazuju visoku neprimetnost stego slike, postoje određena ograničenja:

1. Model je treniran i evaluiran na istom tipu podataka (CelebA).
2. Nije izvršena formalna steganalitička analiza otpornosti na detekciju.
3. Rekonstrukcija skrivene slike pokazuje gubitak finih detalja.

10. Zaključak

Ovaj rad pružio je sveobuhvatan pregled razvoja i primene steganografije slika, od njenih istorijskih korena i klasičnih metoda u prostornom i frekvencijskom domenu, pa sve do savremenih pristupa zasnovanih na dubokom učenju. Teorijska analiza je pokazala da, iako tradicionalne metode poput LSB ugradnje nude jednostavnost i visok kapacitet, one su izuzetno ranjive na steganalitičke napade i uobičajenu obradu slike. Sa druge strane, adaptivne i statističke metode značajno su unapredile neprimetnost i otpornost, ali uz povećanu računarsku složenost.

U okviru praktičnog dela rada, implementiran je *end-to-end* sistem za steganografiju zasnovan na dubokim neuronskim mrežama, koristeći U-Net arhitekturu za enkoder i CNN za dekoder. Eksperimentalni rezultati pokazali su da je model uspešno naučio da ugradi tajnu sliku u nosač uz visok stepen vizuelne sličnosti, što potvrđuje prosečna PSNR vrednost stego slike od približno 35 dB. Iako je rekonstrukcija tajne slike (sa prosečnim PSNR-om od 24 dB) pokazala određeni gubitak finih detalja, globalna struktura i semantički sadržaj su u potpunosti očuvani.

Može se zaključiti da primena veštačke inteligencije u steganografiji otvara nove mogućnosti za bezbednu komunikaciju, omogućavajući automatizovano učenje kompleksnih strategija skrivanja koje prevazilaze mogućnosti ljudskog dizajna algoritama. Budući pravci istraživanja treba da se fokusiraju na poboljšanje kvaliteta rekonstrukcije kroz naprednije funkcije gubitka (poput SSIM ili perceptivnog gubitka) i testiranje robusnosti sistema na agresivne napade poput jake JPEG kompresije ili šuma.

11. Literatura

[1] T. Morkel, J.H.P. Eloff, and M.S. Olivier, "An Overview of Image Steganography," Information and Computer Security Architecture (ICSA) Research Group, Tech. Rep., 2005.
[Online]. Available: https://scispace.com/pdf/an-overview-of-image-steganography-4v02g65fke.pdf
[2] N. F. Johnson and S. Jajodia, "Exploring Steganography: Seeing the Unseen," *IEEE Computer*, vol. 31, no. 2, pp. 26–34, 1998.
[Online]. Available: https://www.jjtc.com/pub/r2026.pdf
[3] S. Baluja, "Hiding Images in Plain Sight: Deep Steganography," *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
[Online]. Available:
https://proceedings.neurips.cc/paper_files/paper/2017/file/838e8afb1ca34354ac209f53d90c3a43-Paper.pdf
[4] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," MICCAI, 2015.
[Online]. Available: https://arxiv.org/pdf/1505.04597 & https://github.com/Miltos-90/UNet_Biomedical_Image_Segmentation
[5] H. Talebi and P. Milanfar, "NIMA: Neural Image Assessment," 2017.
[Online]. Available: https://arxiv.org/pdf/1709.05424.pdf &
https://github.com/idealo/image-quality-assessment
[6] T. M. Jois and G. Beck, "Pulsar: Secure Steganography for Diffusion Models," 2023.
[Online]. Available: https://arxiv.org/pdf/2305.08797.pdf
[7] Z. Liu, P. Luo, X. Wang, and X. Tang, "Deep Learning Face Attributes in the Wild (CelebA)," *Proceedings of ICCV*, 2015.
[Online]. Available: https://mmlab.ie.cuhk.edu.hk/projects/CelebA.html

12. Listing

Slika 1. Ilustracija LSB steganografije – skrivanje informacije izmenom najmanje značajnih bitova piksela bez vidljivog narušavanja kvaliteta slike 14

Slika 2. Primer rada sistema: cover i secret ulazi, stego izlaz i rekonstruisana skrivena slika 33

Slika 3. Primer parova (cover, secret, stego, recovered) nakon završetka treniranja 36

Slika 4. Kretanje funkcije gubitka tokom treniranja 37

Slika 5. Kretanje PSNR metrike tokom treniranja 38

Primer 1. Rezidualna formulacija generisanja stego slike 31

Primer 2. Rekonstrukcija skrivene slike pomoću dekoderske mreže 31

Primer 3. Definicija kombinovane funkcije gubitka 32